Pipeline de Datos con Aplicación de Inteligencia Artificial
Predicción de Eventos Adversos de Medicamentos

Javier Hidalgo // Keylor Mora

1. Introducción

En el contexto actual de la ciencia de datos y la salud, el análisis de información clínica se ha convertido en una herramienta fundamental para mejorar la toma de decisiones y la seguridad del paciente. Uno de los campos más relevantes en este ámbito es la farmacovigilancia, que se encarga del monitoreo y análisis de eventos adversos asociados al uso de medicamentos.

Los eventos adversos pueden variar desde efectos leves hasta situaciones graves que comprometen la vida del paciente. Por esta razón, contar con herramientas que permitan identificar rápidamente la severidad de estos casos es de gran importancia.

En este proyecto se desarrolla un pipeline completo de datos que integra extracción de información desde una fuente real, procesamiento mediante técnicas de ingeniería de datos, almacenamiento en una base de datos, y la aplicación de un modelo de inteligencia artificial capaz de predecir si un evento adverso es serio o no.

2. Fuente de datos

La fuente de datos utilizada en este proyecto es la API pública de **openFDA**, específicamente el endpoint de **Drug Adverse Event**, el cual proporciona acceso a reportes reales de eventos adversos de medicamentos.

Estos datos provienen del sistema FAERS (FDA Adverse Event Reporting System), el cual recopila información sobre pacientes, medicamentos involucrados, reacciones reportadas y características clínicas del caso.

Cada registro está identificado mediante un `safetyreportid`, y contiene múltiples atributos que permiten analizar la severidad del evento.

3. Arquitectura del sistema

El sistema desarrollado sigue una arquitectura de pipeline de datos completa, la cual integra múltiples componentes desde la adquisición de datos hasta la predicción final.

```
API openFDA → ETL → MongoDB → Dataset curado → Modelo Random Forest → Aplicación
```

Diagrama del pipeline

4. Proceso ETL

El proceso ETL (Extract, Transform, Load) es el núcleo del pipeline y se encarga de preparar los datos para su posterior uso.

4.1. Extracción

Se realiza mediante peticiones HTTP a la API de openFDA, obteniendo datos en formato JSON. Se implementa paginación para recolectar múltiples registros.

4.2. Transformación

Durante esta etapa se realizan varias operaciones:

- Limpieza de datos
- Eliminación de duplicados
- Conversión de tipos
- Creación de variables derivadas como:
  - Número de medicamentos
  - Número de reacciones
  - Medicamentos sospechosos
  - Indicadores binarios (has_age, has_country, etc.)

4.3. Carga

Los datos procesados se almacenan en **MongoDB**, utilizando `safetyreportid` como clave para evitar duplicados mediante operaciones de *upsert*.

5. Orquestación del pipeline

Para la automatización del flujo de datos se utilizó **Prefect**, una herramienta de orquestación que permite estructurar el pipeline en tareas y flujos.

El pipeline se divide en tareas como extracción, transformación y carga, permitiendo una ejecución ordenada y controlada.

Prefect permite monitorear la ejecución del pipeline, visualizar logs y detectar errores.

6. Construcción del dataset

A partir de los datos almacenados en MongoDB, se construyó un dataset curado para su uso en el modelo de Machine Learning.

Se seleccionaron variables relevantes, se manejaron valores nulos y se transformaron variables categóricas mediante técnicas como *one-hot encoding*.

El dataset final cuenta con aproximadamente **5000 registros**. La variable objetivo (`target_serious`) indica si el evento adverso es serio o no.

7. Modelo de Machine Learning

Se utilizó un modelo de tipo **Random Forest**, el cual es un algoritmo de aprendizaje supervisado basado en múltiples árboles de decisión.

Este modelo fue seleccionado debido a su robustez, su capacidad para manejar datos tabulares y su buen desempeño sin necesidad de ajustes complejos.

El modelo fue entrenado utilizando una división de datos de 80 % para entrenamiento y 20 % para prueba.

8. Resultados

El modelo obtuvo los siguientes resultados:

- Accuracy: 0.759
- Precision: 0.821
- Recall: 0.7617
- F1-score: 0.7903
- ROC-AUC: 0.8498

La matriz de confusión muestra un desempeño adecuado, aunque con algunos errores en la clasificación de eventos serios.

9. Aplicación

Se desarrolló una aplicación interactiva utilizando **Streamlit**, la cual permite al usuario ingresar variables del caso y obtener una predicción en tiempo real.

La aplicación incluye:

- Formulario simplificado
- Predicción de severidad
- Visualización de probabilidad
- Mini dashboard del dataset

10. Discusión

El proyecto presenta algunas limitaciones como la presencia de ruido en los datos, valores faltantes y simplificación de variables complejas.

Como mejoras futuras se propone el uso de modelos más avanzados, mayor volumen de datos y mejor tratamiento de variables categóricas.

11. Conclusión

El proyecto demuestra la viabilidad de construir un pipeline completo que integra extracción de datos, procesamiento, almacenamiento, modelado y visualización.

Se logró desarrollar una solución funcional que cumple con los objetivos planteados, integrando exitosamente ingeniería de datos e inteligencia artificial.

PROYECTO FINAL · DIAGRAMA

Arquitectura del Proyecto Final

Haga clic en cada etapa para explorar los detalles

PASO 01
API
Fuente de datos

DATOS CRUDOS

PASO 02
ETL
Transformación

DATOS LIMPIOS

PASO 03
MongoDB
Almacenamiento

QUERY / EXPORT

PASO 04
Dataset
Preparación ML

ENTRENAMIENTO

PASO 05
Modelo
Machine Learning

INFERENCIA

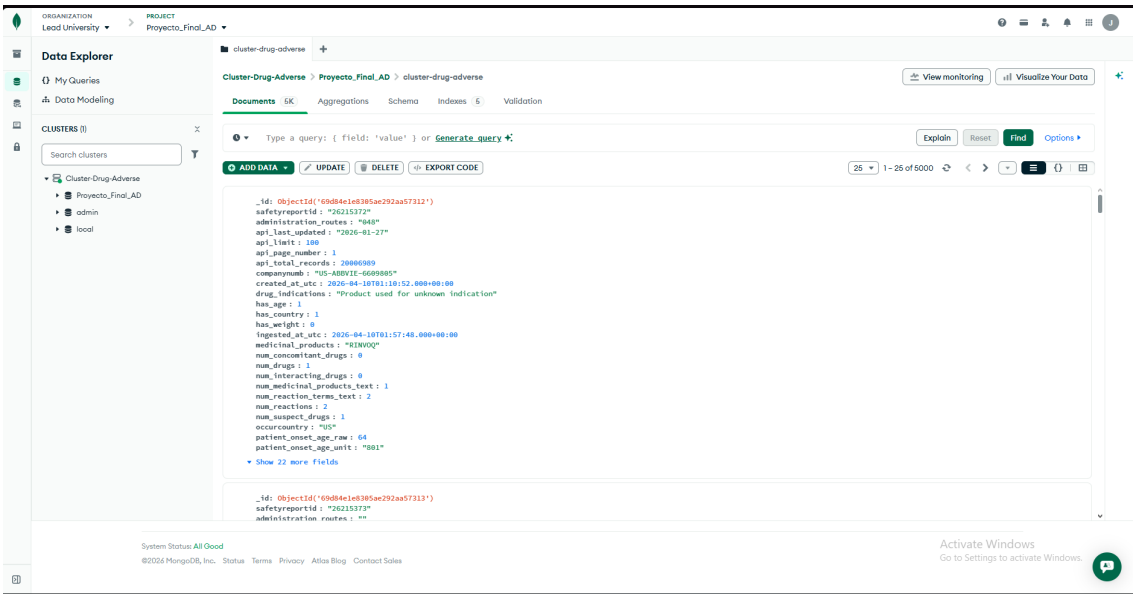

Figura 2: Colección de datos en MongoDB

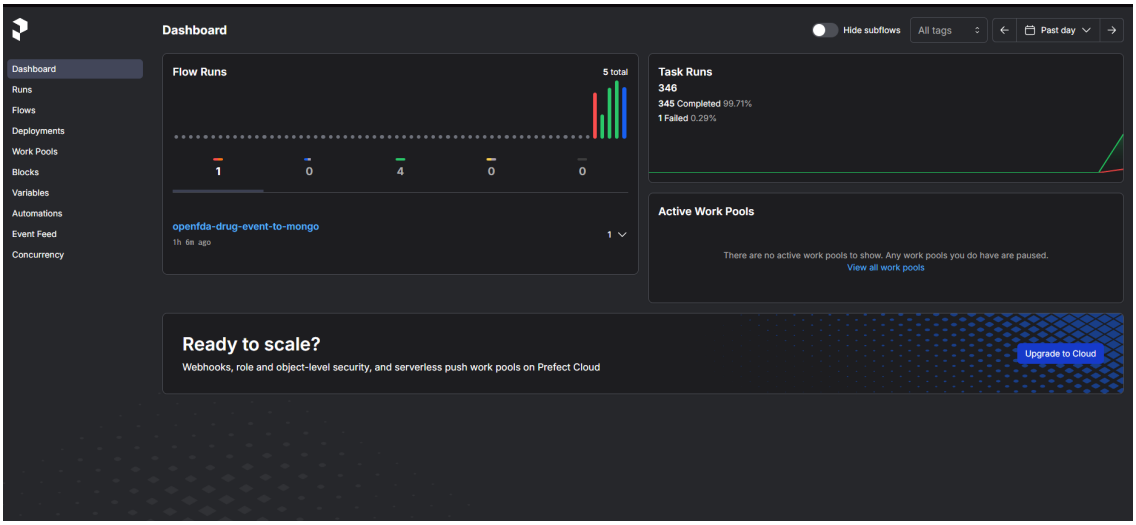

Figura 3: Dashboard de Prefect

Figura 4: Aplicación en Streamlit